





2025/2026

Pneumonia Classification

Progetto Machine Learning



Matteo Pinfildi
0376255

Sommario

Introduzione 2

Analisi del Dataset e Pre-Processing..... 2

Architettura del modello e training 3

Valutazione delle prestazioni..... 3

Explainable AI 4

Introduzione

Il presente progetto si colloca nell'ambito dell'informatica medica, focalizzandosi sulla classificazione supervisionata di radiografie toraciche per la diagnosi automatizzata della polmonite. Per classificazione supervisionata, si intende quel paradigma di machine learning in cui un modello apprende a mappare i dati di input etichettati verso categorie discrete di output, definite in questo contesto come “SANO” e “POLMONITE”.

Per affrontare questa specifica sfida diagnostica, si è scelto di adottare un'architettura basata su Reti Neurali Convoluzionali (CNN). Nell'ambito delle immagini mediche, le CNN rappresentano lo standard di riferimento; tuttavia, operano come se fossero dei modelli “Black Box”, infatti, una volta ricevuto l'input, esse ci restituiscono subito l'output, ovvero la diagnosi, senza esplicitare il perché. Questo è un enorme rischio critico perché la CNN potrebbe identificare delle correlazioni statistiche false, anziché riconoscere dei pattern clinici reali. Per superare queste limitazioni, il progetto integra anche una tecnica di Explainable AI, che permette di validare l'affidabilità del modello e di rendere trasparente il processo decisionale, visualizzando visivamente quali sono le regioni polmonari che hanno guidato la predizione.

Analisi del Dataset e Pre-Processing

La prima cosa fatta è stata analizzare il dataset selezionato. In questa fase sono emerse delle criticità, risolte con delle scelte progettuali ben definite.

Un primo problema riscontrato è lo sbilanciamento del dataset, composto da 1341 immagini di pazienti sani e 3875 di pazienti malati. Addestrare un modello su un dataset così sbilanciato potrebbe portare la CNN a sviluppare un bias verso la classe maggioritaria, che in questo caso è quella dei malati; il modello imparerebbe che diagnosticando sempre la “Polmonite”, otterrebbe un'accuratezza del 75%, senza però imparare a distinguere i reali pattern clinici dei polmoni sani. Per risolvere questo squilibrio, è stata implementata una strategia di Class Weighting, tramite la libreria Scikit-Learn. Assegnando un peso maggiore alla classe “SANO” e uno minore alla classe “POLMONITE”, abbiamo imposto al modello una penalità superiore in caso di errore sui pazienti sani, costringendo la rete a dare la stessa importanza ai pattern visivi di entrambe le classi.

L'analisi ha evidenziato un altro limite strutturale nel dataset, ovvero avere un validation set con solo 16 immagini (8 per i sani e 8 per i malati). Per mitigare questo problema, si è scelto di ignorare la cartella del validation set predefinita, andando poi ad applicare uno split del 20% direttamente sulla cartella di training, così da generare un validation set più robusto, composto da 1043 immagini, fondamentale per monitorare correttamente l'andamento dell'addestramento.

Un'ulteriore sfida è stata rappresentata dalla presenza di artefatti testuali, come la lettera “R” sul bordo delle lastre, che esponevano il modello al rischio di Shortcut Learning, ovvero l'apprendimento di scorciatoie statistiche basate su metadati visivi anziché su pattern clinici. Inoltre, le immagini presentavano risoluzioni elevate e non uniformi, incompatibili con un addestramento efficiente in termini di tempo e risorse. Per risolvere queste criticità, ogni immagine è stata processata tramite una funzione personalizzata che prevede due operazioni: Central Crop e Resizing. Nel Central Crop l'immagine viene tagliata ai bordi, costringendo il modello ad estrarre le feature solo dall'area polmonare; questa operazione è stata definita attraverso un processo iterativo: inizialmente è stata testata un'area di interesse pari a 0.85, ma la “R” risultava ancora visibile, successivamente è stato provato un valore di 0.70, che però appariva troppo aggressivo rischiando di eliminare feature essenziali. La scelta definitiva è ricaduta sul valore medio tra questi due: 0.78. Per Resizing si intende che tutte le immagini sono state ridimensionate alla risoluzione standard di 224x224 pixel.

Infine, per aumentare la robustezza del modello e prevenire l'overfitting, è stata applicata una strategia di Data Augmentation comprensiva di rotazione, zoom e shift dei pixel. È opportuno sottolineare che, per ragioni cliniche, non è stato applicato lo specchiamento orizzontale, perché nell'ambito medico è fondamentale che il cuore si trovi sulla sinistra.

Architettura del modello e training

Per la fase di classificazione, si è scelto di adottare il Transfer Learning, così da ridurre il costo computazionale e limitare il rischio di overfitting, sfruttando l'architettura ResNet50 precedentemente addestrata sul dataset ImageNet. Questa architettura è composta concettualmente da due blocchi: un corpo di strati convoluzionali, specializzato nell'estrazione di caratteristiche visive, e una "testa" finale di classificazione. Poiché la ResNet50 originale è progettata per distinguere 1000 classi eterogenee, è stata rimossa la "testa" originale, inoltre sono stati congelati temporaneamente i pesi di tutti i suoi strati convoluzionali. Al posto della "testa" originale, è stata costruita una nuova "testa" classificativa personalizzata per il dominio clinico. Più nello specifico è stato aggiunto un layer di Global Average Pooling 2D, che permette di appiattire le feature map andando a ridurre drasticamente il numero di parametri rispetto ad un tradizionale layer Flatten. Successivamente è stato inserito un layer Dense da 512 neuroni con funzione di attivazione ReLU. Per garantire che la rete non si focalizzi solo su singoli dettagli rumorosi, è stato aggiunto un livello di Dropout impostato a 0.5 che, disattivando casualmente metà dei neuroni a ogni passaggio, forza il modello a diventare più robusto e capace di generalizzare. La decisione finale è affidata a un neurone con funzione Sigmoid, che comprime l'output in un valore di probabilità tra 0 e 1, ideale per distinguere tra i pazienti "SANI" e quelli affetti da "POLMONITE".


Il training è stato diviso in due fasi. Nella prima è stata addestrata solo la nuova testa classificativa per un massimo di 30 epoche, mantenendo congelato il corpo della ResNet50. Il modello è stato compilato utilizzando l'ottimizzatore Adam e la funzione di perdita Binary Crossentropy, integrando le metriche di Precision e Recall per un monitoraggio clinico più accurato rispetto alla semplice accuratezza. L'EarlyStopping, configurato con una pazienza di 6 epoche, ha interrotto l'addestramento nel momento in cui il modello smetteva di migliorare sui dati di validazione, prevenendo efficacemente l'overfitting e ripristinando i pesi ottimali. Infine, il ReduceLROnPlateau ha permesso di ridurre dinamicamente il learning rate (con un fattore di 0.2) in caso di stallo della `val_loss`, aiutando l'ottimizzatore a convergere in modo più fine verso il minimo globale della funzione di costo.

La seconda fase è quella del Fine-Tuning, in cui è stato specializzato ulteriormente il modello nel campo clinico, infatti la ResNet50 è stata "scongelata" a partire dal 95° strato in poi. Questa scelta strategica permette di mantenere inalterati i primi livelli della rete, che riconoscono feature basilari come bordi e linee, andando invece ad aggiornare i pesi degli strati più profondi, che sono responsabili del riconoscimento di concetti visivi più complessi e specifici. Anche in questa seconda fase è stato implementato l'EarlyStopping e il Fine-Tuning può durare massimo 30 epoche. Il processo di ottimizzazione è stato configurato impostando il learning rate estremamente contenuto, pari a $1e-5$. Questa riduzione è un accorgimento tecnico cruciale: un learning rate troppo alto avrebbe causato aggiornamenti eccessivi, finendo per destabilizzare i pesi pre-addestrati della ResNet50 e vanificando i vantaggi del Transfer Learning.

Valutazione delle prestazioni

La valutazione finale del modello è stata condotta sul test set, ottenendo una accuracy del 92%. Per un'analisi più approfondita sono state generate la curva ROC e la Confusion Matrix. La prima evidenzia un valore di AUC pari a 0.969: un risultato estremamente elevato che attesta l'eccellente capacità della rete nel discriminare tra pazienti sani e malati indipendentemente dalla soglia di classificazione scelta. Proprio questa netta separazione ha permesso di ottimizzare il punto operativo del classificatore, impostando una threshold a 0.7. Mentre il valore standard di 0.5 è spesso influenzato da incertezze nei casi limite, l'adozione di una soglia più restrittiva ha permesso di massimizzare la Precision, riducendo drasticamente gli errori senza però intaccare la sicurezza diagnostica. Dall'analisi della Confusion Matrix, con soglia a 0.7, emerge che il modello eccelle nel minimizzare i falsi negativi. Su un totale di 390 pazienti affetti da polmonite, ne sono diagnosticati correttamente 375, commettendo solo 15 errori; dunque per la classe "POLMONITE" abbiamo una Recall pari al 96%, parametro fondamentale in ambito clinico. La strategia adottata ha puntato al bilanciamento perfetto: alzando la soglia a 0.7 abbiamo alleggerito il carico di Falsi Positivi (limitandoli a soli 34 casi), ma non ci siamo spinti oltre per ridurre il rischio della mancata individuazione della patologia nei veri malati. In termini medici, un falso allarme su un paziente sano può essere risolto con un ulteriore accertamento diagnostico; al contrario, dimettere un paziente malato ritenendolo sano comporterebbe rischi clinici gravissimi. Nonostante il lieve aumento dei Falsi Positivi, il sistema mantiene un F1-Score di 0.94 per la classe dei malati, confermando la stabilità

complessiva del classificatore. In sintesi, i risultati quantitativi descrivono un modello altamente affidabile, capace di agire come un solido strumento di supporto allo screening radiologico.



Explainable AI

Uno dei limiti principali dei modelli di Deep Learning in ambito clinico è la loro natura di Black Box: pur fornendo predizioni accurate, raramente offrono una spiegazione sul processo decisionale adottato. Per superare questa criticità e rendere il modello interpretabile e affidabile per il personale medico, è stata implementata la tecnica Grad-CAM, sfruttando come libreria `tf_keras_vis`. Questa metodologia permette di generare delle heatmap che evidenziano visivamente le aree dell'immagine che risultano essere più rilevanti. Più precisamente l'algoritmo estrae i gradienti che fluiscono nell'ultimo strato convoluzionale della ResNet50 per calcolare l'importanza spaziale delle feature estratte.

Per la visualizzazione finale si è scelto di non ridimensionare la heatmap sull'intera immagine, ma è stata riproiettata solo sulla porzione centrale della radiografia, così da replicare il crop del 78% fatto nella fase di pre-processing. Infine, per mantenere la leggibilità clinica, radiografia e heatmap sono state sovrapposte applicando un rapporto di trasparenza 60/40, preservando così i dettagli anatomici sottostanti.

Dall'analisi dei risultati è emerso che le immagini dimostrano l'efficacia delle scelte di pre-processing. Infatti, in una fase di test preliminare condotta sulle immagini originali, l'analisi Grad-CAM aveva rivelato un evidente fenomeno di Shortcut Learning: il modello tendeva a "barare" basando le proprie predizioni su artefatti laterali, come le lettere di orientamento radiologico ("R"). L'introduzione del Central Crop ha risolto parzialmente questa criticità: le nuove immagini dimostrano che l'attenzione della rete rimane ora rigorosamente confinata all'area polmonare, senza alcuna attivazione anomala sui bordi della radiografia. Oltre a questa correttezza spaziale, emerge una forte coerenza diagnostica: nelle predizioni dei pazienti malati, i picchi di attivazione evidenziati in rosso e giallo si sovrappongono in modo esatto alle macchie bianche presenti nei polmoni, ovvero i tipici segni visivi dell'infezione. Questo conferma che, nelle immagini prive di strumentazioni esterne, il classificatore si focalizza con eccellente precisione sulle aree corrette, fondando la propria decisione sugli stessi marker visivi ricercati da un medico.

Tuttavia, l'analisi visiva delle heatmap ha fatto emergere l'unica reale debolezza residua del modello, legata ad un limite dei dataset clinici: in presenza di dispositivi medici, l'attivazione della rete viene "distratta" da questi dispositivi, che vengono erroneamente interpretati come un marker di gravità clinica, portando la heatmap a sovrapporsi al dispositivo anziché alla patologia sottostante. Questo fenomeno di Shortcut Learning nasce per via di uno squilibrio statistico nel dataset di addestramento, dove i dispositivi medici compaiono quasi esclusivamente nelle radiografie dei

pazienti malati severi. Per risolvere questa criticità alla radice, un possibile approccio prevederebbe due possibili interventi: arricchire il dataset con radiografie di pazienti sani portatori di dispositivi medici, oppure escludere del tutto dal set di addestramento le immagini che presentano tali elementi. L'individuazione trasparente di questo limite avvalorava ulteriormente l'impiego della Explainable AI: non solo per validare le predizioni corrette, ma soprattutto per fornire al medico il contesto critico necessario per individuare e scartare le diagnosi basate su correlazioni spurie.